

Détection automatique de la surcharge de passagers sur motos par vision artificielle

LUBUNGU KISAMBULA Pacifique¹ and ADANLAO Adéyinka Laurinda¹

¹AMA — Académie des Mathématiques Appliquées, Groupe 1

Application déployée : <https://moto-surcharge.streamlit.app> | Code source : <https://github.com/adanlaode/moto-overload-detection>

Abstract

La moto constitue en Afrique un mode de transport dominant, utilisé aussi bien pour l'activité professionnelle (livraison, transport rémunéré de passagers) que pour les déplacements personnels. Au Bénin, ce mode de transport rémunéré est communément désigné sous le nom de zemidjan (ou kèkènon en langue locale). La surcharge de passagers y est fréquente et difficilement contrôlable manuellement, contribuant à l'accidentologie routière. Ce travail s'inscrit dans la dynamique de vidéoprotection engagée par le gouvernement béninois, qui a acté en Conseil des ministres du 4 mars 2026 le déploiement progressif d'un système de vidéoprotection incluant un volet de vidéo verbalisation des infractions routières. Il présente un système de détection automatique de surcharge par vision artificielle, combinant un détecteur d'objets pré-entraîné (YOLOv8) et une logique d'association géométrique passager-véhicule conçue et affinée itérativement, sans réentraînement spécifique au domaine cible, positionné comme brique technique d'aide à la décision susceptible de s'intégrer à ce type d'infrastructure. Le système est évalué quantitativement sur 250 images annotées d'un corpus externe de référence, Le système est évalué quantitativement sur 250 images annotées d'un corpus externe de référence (majoritairement indien), atteignant 66,4% d'exactitude de classification (conforme/surcharge), 92,7% de précision et 57,3% de rappel sur la classe surcharge — des résultats dépassant les méthodes géométriques de référence documentées dans la littérature (58–59% pour des approches comparables). Une vérification qualitative complémentaire sur 134 images de motocyclistes béninois confirme la stabilité opérationnelle du système sur ce contexte, sans toutefois constituer une validation quantitative équivalente. Le système est déployé sous forme d'application web accessible publiquement.

Mots-clés : vision par ordinateur, détection d'objets, YOLOv8, surcharge routière, zemidjan, Bénin, association passager-véhicule, algorithme hongrois.

1 Introduction

1.1 Contexte

En Afrique, la moto constitue un mode de transport dominant, utilisé aussi bien pour l'activité professionnelle — livraison, transport rémunéré de passagers — que pour les déplacements personnels des particuliers propriétaires de leur véhicule. Au Bénin, ce mode de transport rémunéré est communément désigné sous le nom de zemidjan, ou kèkènon en langue locale. Cette étude se concentre spécifiquement sur le contexte béninois.

Le gouvernement béninois a acté, en Conseil des ministres du 4 mars 2026, le déploiement progressif d'un système de vidéoprotection dans plusieurs villes du pays, incluant un volet de vidéo verbalisation des infractions routières (Secrétariat général du Gouvernement du Bénin,

compte-rendu du Conseil des ministres du 04 mars 2026). Ce travail s’inscrit dans cette dynamique : il explore la faisabilité d’un composant de détection automatique de surcharge susceptible de s’intégrer à ce type d’infrastructure, en tant que brique technique d’aide à la décision plutôt que de verbalisation automatique.

1.2 Objectif

Ce travail vise à évaluer la faisabilité d’un système de détection automatique de surcharge sur motos, à partir d’images fixes, en s’appuyant sur des modèles de vision par ordinateur pré-entraînés plutôt que sur un réentraînement complet — un choix méthodologique dicté par une contrainte de temps de développement courte. Il se positionne explicitement comme une brique technique exploratoire, susceptible d’alimenter une réflexion sur l’intégration d’un module de détection de surcharge dans le futur dispositif national de vidéoprotection et de vidéo verbalisation, sans anticiper les choix d’implémentation, de gouvernance ou d’arbitrage juridique qui relèveraient d’une décision publique.

1.3 Portée et contribution

Ce travail se concentre spécifiquement sur le contexte béninois, et couvre l’ensemble des motocyclistes — conducteurs de zemidjan comme motocyclistes à titre personnel. Le zemidjan reste néanmoins le cas d’usage le plus fréquent et sert de fil conducteur pour l’illustration.

Les travaux de référence sur la détection de surcharge (DashCop, TR-TRVD) reposent sur des corpus annotés conséquents (plusieurs centaines de vidéos) pour entraîner un classifieur d’association dédié, atteignant les meilleures performances rapportées (84% pour le *Spatial Attention Classifier* de DashCop). Or, aucun corpus annoté n’est disponible pour le contexte béninois. Ce travail propose et évalue une méthode d’association **sans entraînement dédié** (*training-free*), combinant normalisation géométrique par échelle, estimation de posture par points-clés et résolution par assignment optimal, positionnée comme alternative praticable lorsque la constitution d’un corpus d’entraînement local n’est pas envisageable à court terme.

2 État de l’art

2.1 Détection d’objets généraliste

Les détecteurs *one-stage* de la famille YOLO dominent le champ de la détection en temps réel, grâce à un compromis vitesse/précision favorable par rapport aux détecteurs *two-stage* comme Faster R-CNN. YOLOv8, utilisé dans ce travail, est pré-entraîné sur le jeu de données COCO, qui inclut nativement les classes *person* et *motorcycle*.

2.2 Détection de surcharge sur deux-roues

La détection de surcharge sur motos (*triple riding*) est un champ de recherche actif, principalement documenté en Inde. Goyal et al. [1] (DashCop) proposent un système complet combinant détection, association et classification. Leurs résultats sont particulièrement instructifs : une association par IoU simple atteint 58,5% de précision d’association, une méthode géométrique par trapèze 59,3%, tandis qu’une méthode apprise (*Spatial Attention Classifier*) atteint 84%. Le système complet, en mode entièrement automatique, obtient un F1-score de 72,2%, porté à 82% avec supervision humaine en aval.

2.3 Reconnaissance de plaques d’immatriculation

La reconnaissance de plaques (ANPR) repose classiquement sur une détection de la zone plaque suivie d’une étape de reconnaissance de caractères (OCR). Une étude académique béninoise [2]

rapporte des résultats de 86% de rappel et 60% de précision pour une méthode classique de détection de plaques béninoises.

3 Données

3.1 Constat sur la disponibilité des données

Aucun corpus public annoté spécifiquement pour le zemidjan béninois n’a été identifié. Deux corpus ont été mobilisés pour ce travail :

- un corpus externe de référence (Roboflow *Tripple_Riding*), utilisé pour le calibrage et l’évaluation quantitative ;
- un corpus contextuel béninois, constitué pour ce travail, servant de vérification qualitative de stabilité.

3.2 Nettoyage du corpus externe

Le corpus Roboflow *Tripple_Riding* (2870 annotations) présentait 16 classes issues d’une contribution communautaire non harmonisée (plusieurs orthographes et casses désignant les mêmes concepts, par exemple *Triple Riding*, *triple-riding*, *triple_rider*, *tripples-riding*). Ces classes ont été regroupées manuellement en 7 catégories cohérentes après vérification visuelle systématique : **bike**, **surcharge**, **double_riding**, **single_riding**, **helmet**, **no_helmet**, **rider_individuel**. Le Tableau 1 résume ce regroupement.

Table 1: Regroupement des 16 classes originales en 7 catégories cohérentes

Catégorie finale	Classes originales fusionnées	Effectif
surcharge	Triple Riding, Tripping, triple-riding, triple-riding-bikes, triple_rider, tripples-riding	1 154
no_helmet	No_helmet, without helmet	506
rider_individuel	Rider	355
double_riding	Double riding, double_rider	257
helmet	Helmet_On, pillion helmot	242
single_riding	single rider, single_rider	200
bike	Bike	156

3.3 Corpus contextuel béninois

Un second corpus de 134 images de motocyclistes béninois (zemidjan et usage personnel) a été constitué par collecte en ligne, pour vérifier la stabilité du système calibré sur un contexte visuel différent de celui du corpus d’entraînement/calibrage. Ce corpus ne dispose pas de vérité terrain indépendante systématique et sert exclusivement de vérification qualitative.

4 Méthodologie

4.1 Vue d’ensemble du pipeline

Le système se décompose en quatre étapes : (1) détection d’objets (motos, personnes) par YOLOv8 pré-entraîné ; (2) filtrage des détections par seuil de confiance ; (3) association géométrique entre personnes détectées et motos ; (4) classification par seuil du nombre de personnes associées à chaque moto.

4.2 Détection et filtrage

YOLOv8 (variante *nano*) est utilisé sans réentraînement pour détecter les classes *person* et *motorcycle*. Un second modèle, YOLOv8-pose, extrait en complément 17 points-clés corporels par personne détectée (format COCO), dont les points de hanche gauche et droite, utilisés comme point d’ancrage pour l’association.

4.3 Association passager-moto : démarche itérative

L’association entre une personne détectée et la moto à laquelle elle appartient constitue le principal verrou méthodologique de ce travail, YOLOv8 ne fournissant aucune information relationnelle entre objets détectés. Cinq approches ont été successivement testées :

1. **Zone élargie autour de la moto** : test d’appartenance du centre de la boîte personne à une zone élargie autour de la boîte moto. Sujette au double comptage d’une même personne pour plusieurs motos.
2. **Plus proche voisin** : association à la moto la plus proche en distance euclidienne. Sensible aux effets de perspective (distances non normalisées par la profondeur apparente).
3. **Chevauchement horizontal normalisé** : introduction d’un critère d’alignement horizontal avec marge de tolérance. Insuffisant en présence de piétons proches d’une moto.
4. **Normalisation par échelle et assignment optimal** : les distances sont normalisées par les dimensions de la boîte moto, et l’association est résolue par l’algorithme hongrois (Algorithme 1).
5. **Estimation de posture** : les points-clés de hanche remplacent le centre de boîte comme point d’ancrage, combinés à une déduplication par IoU pour éliminer les détections dupliquées d’une même personne en cas de forte occlusion.

La combinaison des approches 4 et 5 constitue la méthode retenue pour l’application déployée.

4.4 Algorithme d’association

L’Algorithme 1 formalise la méthode retenue. Pour éviter la limitation de l’algorithme hongrois classique à une association un-à-un, chaque moto est dupliquée en K colonnes virtuelles dans la matrice de coût (représentant K places passager disponibles), permettant l’association de plusieurs personnes à une même moto tout en conservant la garantie d’optimalité globale de l’assignment.

Algorithm 1 Association passager-moto par assignment optimal

Require: Personnes détectées $P = \{p_1, \dots, p_n\}$ avec points-clés de hanche ; motos détectées $M = \{m_1, \dots, m_k\}$; K = places max. par moto (6)

Ensure: Association $A : P \rightarrow M \cup \{\emptyset\}$

- 1: **Déduplication** : trier P par confiance décroissante ; retirer p_i si $\exists p_j$ déjà retenu avec $\text{IoU}(p_i, p_j) > 0,5$
- 2: **Ancrage** : pour chaque $p_i \in P$, calculer $a_i = \text{moyenne}(\text{hanche_gauche}, \text{hanche_droite})$ si confiance $> 0,3$, sinon exclure p_i
- 3: **for** chaque p_i , chaque m_j **do**
- 4: $d_x \leftarrow |a_i^x - \text{centre}_x(m_j)| / \text{largeur}(m_j)$
- 5: $d_y \leftarrow (a_i^y - \text{centre}_y(m_j)) / \text{hauteur}(m_j)$
- 6: **if** $d_x > 1,2$ **ou** $d_y < -0,5$ **ou** $d_y > 1,5$ **then**
- 7: $C_{i,j} \leftarrow \infty$ ▷ paire jugée non plausible
- 8: **else**
- 9: $C_{i,j} \leftarrow d_x + \max(0, d_y)$
- 10: **end if**
- 11: **end for**
- 12: **Duplication** : construire C' en répétant chaque colonne j de C , K fois
- 13: (lignes, colonnes) $\leftarrow \text{ALGORITHMEHONGROIS}(C')$ ▷ `scipy.optimize.linear_sum_assignment`
- 14: **for** chaque paire (r, c) retenue **do**
- 15: $j \leftarrow \lfloor c/K \rfloor$ ▷ colonne virtuelle $\rightarrow$ moto réelle
- 16: **if** $C_{r,j} < \infty$ **then**
- 17: $A(p_r) \leftarrow m_j$
- 18: **end if**
- 19: **end for**
- 20: **return** A

4.5 Classification finale

Le nombre de personnes associées à chaque moto est comparé à un seuil réglementaire configurable (fixé par défaut à 3, correspondant à un conducteur et un passager maximum autorisés) :

$$\text{statut}(m_j) = \begin{cases} \text{surcharge} & \text{si } |\{p_i : A(p_i) = m_j\}| \geq 3 \\ \text{conforme} & \text{sinon} \end{cases}$$

5 Mise en œuvre

5.1 Architecture logicielle

Le système est implémenté en Python et repose sur les composants suivants :

- **Détection et posture** : ultralytics (YOLOv8n, YOLOv8n-pose), inférence CPU compatible avec un déploiement sans GPU dédié ;
- **Traitement d'image** : OpenCV (lecture, annotation, conversion d'espaces colorimétriques) ;
- **Résolution de l'assignment** : `scipy.optimize.linear_sum_assignment` (implémentation de l'algorithme hongrois) ;
- **Interface applicative** : Streamlit, déployée sur Streamlit Community Cloud ;
- **Lecture de plaque (module optionnel)** : EasyOCR.

5.2 Environnement de développement et d'entraînement

Les expérimentations (calibrage, fine-tuning, évaluation) ont été menées sur Google Colab, avec accès à un GPU Tesla T4. Le fine-tuning du détecteur (section 6.4) a nécessité 23 époques (arrêt anticipé) sur 2 747 images, pour un temps d'entraînement total inférieur à 20 minutes.

5.3 Calibrage du détecteur de moto

Le seuil de confiance de détection moto a été calibré empiriquement sur le corpus de validation (250 images), en testant quatre valeurs (Tableau 2). La valeur 0,20 a été retenue, au-delà de laquelle aucun gain supplémentaire n'est observé (plateau confirmé à 0,15).

Table 2: Sensibilité au seuil de confiance de détection moto

Seuil	Exactitude statut	Précision	Rappel
0,40 (défaut)	62,0%	0,928	0,506
0,30	64,8%	0,925	0,551
0,20 (retenu)	66,4%	0,927	0,573
0,15	66,4%	0,927	0,573

5.4 Reproductibilité

Le code source, les scripts d'entraînement et d'évaluation, ainsi que la liste des dépendances sont disponibles dans le dépôt GitHub accompagnant ce travail. Les modèles pré-entraînés utilisés (YOLOv8n, YOLOv8n-pose) sont ceux publiés par Ultralytics. Le corpus d'évaluation quantitative provient d'une source publique (Roboflow Universe), et le script de nettoyage des classes est fourni pour permettre une reproduction exacte du regroupement effectué.

6 Résultats

6.1 Évaluation quantitative sur corpus annoté

Une première évaluation (seuil de confiance de détection moto à 0,4, valeur par défaut) a révélé une exactitude de statut de 62,0%, avec un déséquilibre marqué entre précision (92,8%) et rappel (50,6%). L'analyse des erreurs de sous-estimation a mis en évidence que, dans plusieurs cas, la moto elle-même n'était pas détectée par le détecteur de base, notamment en situation de forte occlusion du véhicule par un nombre élevé de passagers. Après calibrage du seuil (section ??), la configuration retenue atteint **66,4% d'exactitude de statut, 92,7% de précision et 57,3% de rappel** sur les 250 images évaluées.

Un mécanisme de repli sur le centre de la boîte englobante en l'absence de points-clés de hanche fiables a également été testé, sans effet mesurable sur les métriques — confirmant que le facteur limitant principal était la détection de la moto elle-même plutôt que l'étape d'association.

6.2 Application au contexte cible

Le pipeline calibré a été appliqué au corpus de 134 images béninoises. 130 images (97,0%) ont produit une détection exploitable, un taux cohérent avec celui observé sur le corpus de calibrage, suggérant une généralisation raisonnable du seuil retenu à ce second contexte visuel. Ce corpus ne disposant pas de vérité terrain indépendante systématique, il ne permet pas de calcul de métriques comparables à la section précédente.

6.3 Comparaison qualitative avant/après correction

Le Tableau 3 illustre le gain apporté par les corrections méthodologiques successives sur deux cas vérifiés visuellement.

Table 3: Comparaison avant/après sur deux cas vérifiés

Image	Vérité terrain	Méthode simple	Méthode finale
Cas A (scène dégagée)	2 pers., conforme	6 pers., surcharge (faux)	2 pers., conforme (correct)
Cas B (arrière-plan chargé)	3 pers., surcharge	2 pers., conforme (faux)	3 pers., surcharge (correct)

6.4 Tentative de fine-tuning

Un fine-tuning de YOLOv8 sur un corpus externe annoté (VIDES2023, 2 747 images) a atteint un mAP50 de 99,1% sur la classe *Rider* en validation interne. Ce modèle n’a cependant pas généralisé aux images du corpus d’évaluation, illustrant un phénomène de décalage de domaine (*domain gap*) entre les conditions de capture homogènes du corpus d’entraînement et la diversité des conditions du corpus de test.

7 Discussion

7.1 Positionnement par rapport à la littérature

Les résultats obtenus (66,4% d’exactitude de statut) sont cohérents avec, et légèrement supérieurs à, ceux documentés dans la littérature de référence (58–59% pour des méthodes géométriques comparables [1]), ce qui valide empiriquement la pertinence des améliorations successives apportées à la méthode d’association et au calibrage du détecteur. Le profil précision/rappel observé (haute précision, rappel modéré) indique un système conservateur, adapté à un usage d’aide à la décision humaine plutôt qu’à une verbalisation automatique.

7.2 Limites

- **Rappel modéré (57,3%)** : le système rate encore 42,7% des surcharges réelles, concentrées sur les cas d’occlusion extrême où la moto devient difficile à détecter visuellement.
- **Absence de réentraînement adapté au domaine cible.**
- **Corpus d’évaluation externe**, non spécifique au Bénin.
- **Module ANPR non opérationnel**, stade de preuve de concept.
- **Absence de cadre juridique traité** pour une éventuelle verbalisation automatique.

7.3 Considérations éthiques

Le système est délibérément positionné comme un outil d’aide à la décision humaine. L’usage de vidéosurveillance à des fins de contrôle routier pose des questions de proportionnalité et de finalité non traitées ici. Le corpus externe majoritairement indien introduit un risque de biais de représentation. Enfin, toute mise en œuvre devrait s’accompagner d’une réflexion sur les conséquences socio-économiques pour les conducteurs de zemidjan, activité constituant une source de revenu significative.

7.4 Perspectives

L'analyse des erreurs identifie une limite structurelle : au-delà d'un certain niveau d'occlusion, la moto devient indétectable quel que soit le seuil appliqué. Deux directions se dégagent : un détecteur fine-tuné spécifiquement sur des cas d'occlusion forte, et un classifieur entraîné sur crop de scène plutôt qu'une association individuelle (67,7% de F1-score rapporté par DashCop contre 23% pour un simple comptage). Le tracking vidéo (ByteTrack), non implémenté faute de données vidéo disponibles, constitue une perspective directe pour stabiliser l'association dans le temps.

8 Conclusion

Ce travail présente un système fonctionnel de détection de surcharge de passagers sur motos, construit à partir de modèles pré-entraînés et d'une méthode d'association géométrique affinée itérativement, sans nécessiter de corpus annoté spécifique au contexte cible. Les résultats quantitatifs (66,4% d'exactitude, 92,7% de précision) portent sur un corpus externe de référence et ne constituent pas une validation définitive sur les motocyclistes béninois, la vérification sur le contexte cible restant qualitative. Sous cette réserve explicite, les résultats dépassent les méthodes géométriques de référence documentées dans la littérature, suggérant qu'une approche sans entraînement constitue un point de départ raisonnable pour des contextes à faibles ressources de données. Le système est déployé sous forme d'application web démonstrative, accessible publiquement.

References

- [1] Goyal, S. et al. (2025). *DashCop: Automated E-ticketing for Triple Riding and Helmet Violation Detection*. arXiv:2503.00428.
- [2] Djara, T., Assogba, M.K., Vianou, A. *Étude de reconnaissance de plaques d'immatriculation béninoises*. École Polytechnique d'Abomey-Calavi.
- [3] Ultralytics. *YOLOv8 Documentation*. <https://docs.ultralytics.com>
- [4] Roboflow Universe. Jeux de données *Triple Riding Detection* et *Tripple_Riding* (divers contributeurs).
- [5] NVIDIA AI City Challenge, Track 5 — *Detecting Violation of Helmet Rule for Motorcyclists*.